AUDITORÍA DEL PROYECTO · FASES 1 A 9

exoplanet-ml: auditoría completa y propuestas de métodos nuevos

Revisión de lo hecho en las fases 1–6 (código, resultados, decisiones y Notion), lista de lo que conviene corregir y exploración de 22 métodos que el proyecto aún no ha probado, con un experimento mínimo para cada uno.

6 de noviembre de 2026 · Preparado por Claude para Jairo · Fuentes: repositorio (`research/01-14`, `src/`, `scripts/`, `results/`), las bases de datos Fases y Tareas de Notion y literatura de 2018–2026 (al final).

---

1. Resumen ejecutivo
2. Cómo está el proyecto, fase por fase
3. Lo que está bien hecho
4. Hallazgos: qué corregir o revisar
5. Métodos nuevos: exploración
6. Hoja de ruta propuesta
7. Decisiones que te tocan
8. Qué haría distinto un equipo real
9. Fuentes

---

1. Resumen ejecutivo

Las fases 1 a 6 están cerradas. El modelo final es una CNN de dos ramas tipo AstroNet que solo ve la curva (vistas global y local normalizadas, sin profundidad), entrenada con Kepler, K2 y TESS, con un conjunto de 5 semillas y temperatura por misión. Se evaluó una sola vez en test con la receta fijada antes de mirarlo (commit `05a737a`).

0,886 Macro-F1 en test, Kepler [0,867–0,906]	**0,928** Macro-F1 en test, K2 [0,858–0,983]	**0,720** Macro-F1 en test, TESS [0,661–0,772]	**0,761** PR-AUC de TESS sin haberlo visto (LOMO, test)

Veredicto. El rigor metodológico está muy por encima de un proyecto de estudiante típico: protocolo LOMO anidado, test intacto hasta el final, atajos medidos, negativos emparejados y resultados nulos documentados. Los puntos débiles no son de rigor. Son de cinco tipos:

1. **Potencia estadística.** Algunos experimentos de TESS no podían detectar el efecto que buscaban. El caso más claro es el de los varios sectores de la fase 6, que contradice sin resolverla la mejora de la fase 3.
2. **Representación de la curva.** La vista local tiene ~10 bins por duración del tránsito y faltan las vistas par/impar local y del secundario. Justo eso es lo que separa las binarias de TESS, que se escapan como planeta un 31 % de las veces.
3. **Negativos poco realistas.** NO_SIGNAL se fabrica con una efeméride al azar en estrellas tranquilas, y por eso es demasiado fácil. Existen falsas alarmas reales públicas (Kepler DR25 invertido y desordenado, FA de TESS) que no se han usado.
4. **Alternativas sin probar.** Varias líneas se cerraron sin probar las alternativas de mayor rendimiento esperado: pesos por misión, etiquetas débiles, adaptación adversarial de dominio y el centroide como modalidad opcional en LOMO.
5. **Higiene del repositorio.** El trabajo de la fase 6 no está en git aunque Notion la da por hecha, y `AGENTS.md`, `README.md` y `CONTEXTO.md` están desactualizados.

Las 8 propuestas que más recomiendo

#	Propuesta	Qué ataca	Coste	Novedad
1	Medir los varios sectores **en inferencia** con el modelo actual (comparación pareada) y, si ayuda, promediar por sectores (A1)	Contradicción fase 3 (+0,034) / fase 6 (−0,019)	XS–S	Baja
2	Vistas par/impar local, secundario local y local de alta resolución (P2)	Binarias de TESS tomadas por planeta (31 %)	M	Baja, valor alto
3	Negativos realistas: Kepler DR25 invertido y FA de TESS (P7)	NO_SIGNAL demasiado fácil; triaje sin efeméride	M	Media
4	Inyectar binarias y planetas de periodo corto en curvas reales (P6)	Población distinta de TESS («periodo corto → binaria»)	M–L	Media
5	Pesos por misión y clase, después entrenamiento adversarial de dominio (A4, P12)	Kepler pesa el 75 % de la pérdida; la misión se adivina (AUC 0,73–0,92)	S → M	Alta (DANN)
6	Predicción conformal por misión + detector fuera de distribución (P15, P16)	Honestidad de la herramienta («no se puede decidir»)	S	Media–alta
7	Congelar ya la v1 y añadir una validación **pseudo-prospectiva** por fecha de alerta del TOI (P17)	La validación prospectiva tarda meses o años	S–M	Alta
8	Transformer sobre el conjunto de tránsitos individuales (P1)	Pocos tránsitos en TESS; lo que la mediana borra	L	Alta (no encontrado)

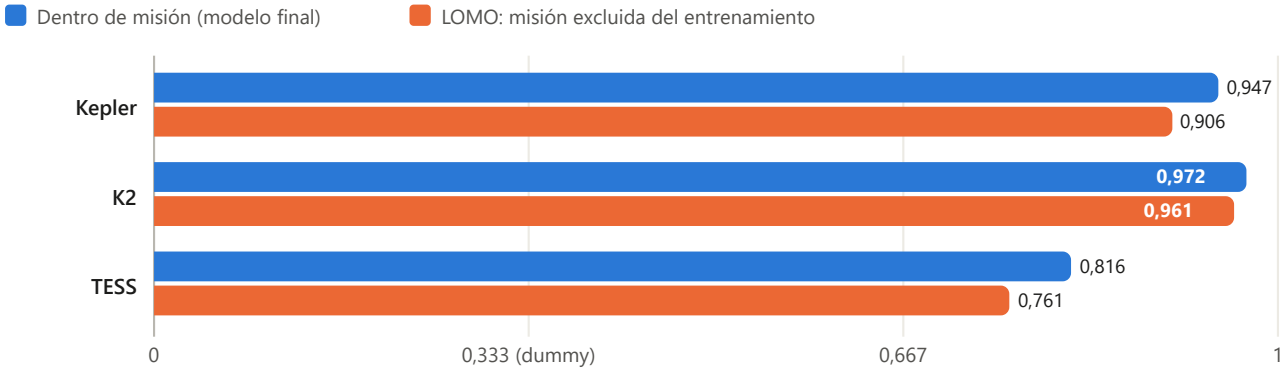
Coste con la escala de Notion: XS < 1 h, S ~ medio día, M 1–2 días, L 3–5 días. «Novedad» se refiere a si el método se ha publicado para este problema, según búsquedas no exhaustivas del 6 nov 2026.

Antes de nada (higiene, < 1 h): hacer commit del trabajo de la fase 6 (`research/14` , `scripts/models/temperature.py` , `tess_multisector.py` , `build_tess_multisector.py` , `tess_multi_compare.py` y sus CSV) y actualizar `AGENTS.md` (dice que la fase 3 está «sin ejecutar»), `README.md` (estado del 4 nov) y `CONTEXTO.md` (5 fases). Ninguna de estas acciones se ha hecho en esta auditoría: no he modificado nada del repositorio ni de Notion.

2. Cómo está el proyecto, fase por fase

Fase	Qué se hizo	Resultado clave	Valoración
1 Datos	Curvas propias de MAST, plegado propio igual en las tres misiones, etiquetas armonizadas (solo fuertes en evaluación), negativos NO_SIGNAL emparejados por sector y brillo, tests de atajo y de fuga, exclusión por coordenadas.	17 164 estrellas (~14 700 válidas). Atajo PLANET vs NO_SIGNAL sin tránsito: 0,55–0,60.	Muy buena. Débil: negativos con efeméride al azar; vistas de baja resolución.
2 Modelos por misión	Escalera completa: dummy → logística → kNN → boosting → MLP → CNN → MOMENT (congelado y ajustado) → centroide.	CNN: 0,833 de media de semillas, 0,850 con conjunto de 3. Seis familias se quedan entre 0,81 y 0,84.	Muy buena. Débil: selección con una semilla; solo aumento por reflexión.
3 LOMO	Protocolo anidado; AdaBN, recorte, pseudo-etiquetas, 2 sectores, ablación de la profundidad, calibración con cambio de prior.	PR-AUC 0,894 / 0,927 / 0,764 (media 0,862 frente a 0,911 dentro de misión). 2 sectores: +0,034 [+0,018, +0,048].	Excelente diseño. Débil: solo un método de adaptación no supervisada; LOMO con centroide pendiente.
4 Modelo final	Estado del arte, BLS, receta commiteada antes del test, test único, análisis de errores, negativos difíciles.	Test 0,886 / 0,928 / 0,720. Con efeméride de BLS, el macro-F1 cae a ~0,45–0,50.	Ejemplar. Débil: la decisión sobre los negativos difíciles quedó abierta.
5 Búsqueda	Triaje SDE + CNN, 3 picos de BLS, CNN sobre la curva sin plegar con inyecciones, revisión de herramientas existentes.	Recall 0,564 con un 1 % de falsas alarmas; con recall 95 % pasa el 66 % del ruido.	Buena y bien cerrada. La arquitectura sin plegar era sencilla; la U-Net de la fase 7 es el paso lógico.
6 TESS	Vistas con varios sectores y reentrenamiento, etiquetas extra (aparcadas), temperatura por misión.	Multisector −0,019 [−0,059, +0,018]; ECE de Kepler 0,039 → 0,017.	Débil en potencia: la conclusión «no mejora» no es concluyente (A1).
7–9	Sin empezar (7, 8) o en curso sin tareas activas (9).	—	Ver hoja de ruta (sección 6).

PR-AUC macro en test: viéndolo al entrenar frente a sin haberlo visto (LOMO)



Fuente: `results/models/final_test.csv` y `lomo_cnn_nodepth_test.csv`. La pérdida por no haber visto el telescopio es pequeña en Kepler y K2. TESS es difícil incluso viéndolo: el cuello de botella está en sus datos.

La métrica que importará en las fases 7 y 8

Para vigilar TOIs, la pregunta real es planeta frente a FP entre señales ya detectadas, no la de 3 clases con NO_SIGNAL fabricado 1:1. La he calculado ahora sobre las predicciones guardadas, con la puntuación $p_P/(p_P+p_{FP})$ (no estaba en el repositorio):

Test, solo PLANET y FP	n	Prevalencia de planetas	ROC-AUC	PR-AUC	Recall con precisión 0,9

Kepler, modelo final	561	0,33	0,966	0,909	0,77
K2, modelo final	39	0,51	0,995	0,995	1,00
TESS, modelo final	147	0,39	**0,803**	**0,766**	**0,34**
TESS, LOMO (sin verlo)	147	0,39	0,796	0,739	0,17
Kepler, LOMO (sin verlo)	561	0,33	0,932	0,798	0,00

Ese 0,766 es la cifra que hay que poner junto a ExoMiner++ (PR-AUC 0,976 en TESS, con centroide, imagen de diferencia y parámetros estelares). No son los mismos datos, pero da la escala del techo de «solo curva». Con n = 147, su IC es amplio.

3. Lo que está bien hecho (y hay que mantener)

- **Test intacto hasta el final**, con la receta commiteada antes de mirarlo. Las cifras de LOMO en test coinciden con las de val: la selección no infló los resultados.
- **Protocolo LOMO anidado**: la misión excluida no participa en ninguna decisión. No hemos encontrado una evaluación de tres telescopios así publicada (research/08).
- **Atajos medidos de forma sistemática**: NaN del catálogo, metadatos del proceso, número de sectores, centroide. Se cerró el atajo de sectores emparejando negativos.
- **Errores corregidos y documentados**: MJD→BKJD, sectores ≥ 100 de TESS, ventana fija de par/impar, negativos cerca de candidatos.
- **Resultados nulos escritos**: AdaBN, recorte, pseudo-etiquetas, 3 picos de BLS, multisector. Pocos proyectos lo hacen.
- **Criterios fijados antes de mirar** en pseudo-etiquetas y multisector.
- **Revisión de herramientas existentes antes de construir** (research/13), que evitó rehacer TFOP, ExoClock o ExoMiner++.
- **Reproducibilidad**: semillas, negativos idénticos byte a byte, requisitos fijados, pesos guardados.

4. Hallazgos: qué corregir o revisar

Gravedad: **ALTA** puede cambiar una conclusión o una decisión; **MEDIA** mejora probable o riesgo moderado; **BAJA** limpieza.

4.1 Metodología y estadística

ALTA **A1 · El experimento multisector de la fase 6 no tenía potencia para decidir**

Evidencia. Fase 3: el mismo modelo LOMO evaluado en las mismas 1 278 estrellas con 1 o 2 sectores gana +0,034 [+0,018, +0,048]. Es una comparación pareada y casi sin varianza de entrenamiento. Fase 6: se reentrena con vistas multisector y se evalúa en las 302 de val, con −0,019 [−0,059, +0,018]. Las estrellas que *no* ganan sectores bajan casi lo mismo (−0,025) que las que ganan (−0,014). Lo que se ve es variación entre entrenamientos, no el efecto de los sectores. Con 134 estrellas y un IC de ±0,08, un efecto de +0,03 era indetectable.

Propuesta. (1) Evaluar el modelo actual (entrenado con 1 sector) en las vistas multisector ya construidas (`data/sample/views_tess_multi`), pareado por estrella. Mide el efecto de la información sin ruido de entrenamiento y cuesta minutos. (2) Si sale positivo, **promediar en inferencia**: plegar cada sector por separado y promediar las probabilidades, o usar la vista multisector solo al predecir, sin reentrenar. (3) Para comparar reentrenamientos, usar validación cruzada de 5 particiones sobre TESS train + val (~2 630 estrellas en lugar de 302) y diferencias pareadas por semilla.

MEDIA **A2 · Selección de configuración con una sola semilla**

La rejilla final (`final_select.csv`) eligió base 16 / dropout 0,5 con la semilla 0 (0,839 frente a 0,812–0,834), y la desviación entre semillas es de 0,01–0,05 (fase 2). La elección puede ser suerte, como pasó con la semilla 0 de la CNN sin plegar (0,554, frente a 0,498 de media). **Propuesta:** elegir con la media de ≥ 3 semillas, o con CV. Es barato con la GPU.

MEDIA **A3 · Muchas variantes evaluadas sobre el mismo val de TESS**

Sobre las ~300 estrellas de val de TESS se han probado al menos 10 variantes: centroide, par/impar, diagnósticos, efeméride, MOMENT, AdaBN, recorte, pseudo-etiquetas, negativos difíciles y multisector. El test se protegió bien, pero cualquier «mejora» futura en val de TESS tiene un riesgo alto de ser azar (el jardín de senderos que se bifurcan). **Propuesta:** llevar en `docs/decisiones.md` (#40) un contador de variantes probadas por conjunto de evaluación. Antes de cada experimento, calcular el efecto mínimo detectable con el n disponible (análisis de potencia). Usar CV sobre train + val para lo exploratorio.

ALTA **A4 · La pérdida está dominada por Kepler y la métrica es la media de misiones**

En el entrenamiento conjunto, Kepler aporta ~9 930 estrellas, TESS ~2 630 y K2 ~650 (≈ 75 / 20 / 5 %). Los pesos son solo por clase (`training.fit`), así que el modelo optimiza sobre todo Kepler, mientras la selección y la métrica principal promedian misiones. `research/07` ya lo apuntaba («razón probable: desequilibrio»; «dar más peso a TESS … sin probar»). **Propuesta:** pesos por (misión × clase) o un muestreador equilibrado por misión, y como variante Group DRO (minimizar la pérdida de la peor misión). Criterio fijado antes: el macro-F1 de TESS sube con un IC de la diferencia sin 0 y Kepler/K2 no bajan más de 0,01. Coste S.

MEDIA **A5 · Las etiquetas débiles nunca se han usado al entrenar**

`research/04` dejó pendiente comparar «fuertes» frente a «fuertes + débiles», y el protocolo lo permite como variante elegida en los folds internos. Son 1 631 candidatos de Kepler (Robovetter), 899 de K2 y 3 802 PC de TESS. **Los PC de TESS deben quedarse fuera**, porque son el conjunto de la validación prospectiva (#85–#92). En Kepler, `koi.csv` tiene `koi_score`, que sirve como etiqueta blanda (ver P10).

MEDIA **A6 · Decisiones que quedaron abiertas y condicionan las fases 7–8**

- **Negativos difíciles** (`research/11` §3: «adoptar, descartar o una fracción menor»). Cuestan −0,03/−0,04 con la efeméride de catálogo y aportan +0,2 con la de BLS. Propuesta: el modelo base para los modos con efeméride dada (TOIs) y el de negativos difíciles solo para búsqueda, por escrito.
- **Frontera FP «no parece tránsito» frente a NO_SIGNAL** (22–24 % de esos FP van a NO_SIGNAL). Cambia el significado de NO_SIGNAL en el informe al aficionado.
- **#9, test z par/impar con block bootstrap**, aparcada. Es necesaria si el informe de la fase 8 muestra «par/impar significativo».

MEDIA **A7 · Probabilidades para TOIs: el prior y la calibración no corresponden a esa población**

El modelo se entrena con pesos «balanced» (clases equiprobables) y la temperatura se ajusta en val con NO_SIGNAL 1:1. En los TOIs abiertos, NO_SIGNAL casi no existe y la fracción de planetas es otra. Además, la temperatura (un parámetro) no corrige errores por clase, y se ajustó con el conjunto entrenado solo con train, pero se aplica al de train + val. **Propuesta:** para la fase 7, publicar P(planeta | señal) = $p_P/(p_P+p_{FP})$, calibrada con regresión isotónica o de Platt sobre los PLANET/FP de val de TESS. Mostrar cómo cambia la precisión con el prior estimado de los TOIs (reajuste de Bayes) y probar el escalado por vector/Dirichlet fuera de pliegue.

BAJA **A8 · La métrica de 3 clases infla el resultado frente al uso real**

Ya está documentado (NO_SIGNAL 1:1, macro-F1 para comparar modelos y no como rendimiento esperado). Para las fases 7–9, conviene que la cifra de cabecera sea la binaria planeta frente a FP de la sección 2 (TESS PR-AUC 0,766) y la precisión con un prior realista (`research/11` §2).

4.2 Datos y representación

ALTA **B1 · Resolución de las vistas: la forma del borde del tránsito apenas se ve**

La local tiene 81 bins en ±4 duraciones, es decir, **~10 bins por duración**. Con τ/T ≈ 0,1–0,3, la entrada y la salida ocupan 1–3 bins. El propio EDA lo vio: «τ/T ≈ 0,25 y no 0,09 como en la teoría, porque el binning (T ≈ 10 bins) suaviza los bordes» (`research/02` §5). Y la forma U frente a V es lo que separa una binaria. En la global (201 bins), un tránsito con duty 0,01 ocupa ~2 bins: esa rama ve sobre todo el secundario y la variabilidad. AstroNet usa 201 bins en la local y 2 001 en la global. Un trabajo de 2026 («Depth-Blind by Design») encuentra que la rama global aporta ≤ 0,005 de PR-AUC en un clasificador de Kepler aplicado a TESS. **Propuesta:** P2 y P4.

ALTA **B2 · Faltan las vistas que usan AstroNet-Vetting y ExoMiner para detectar binarias**

La opción 2 de `research/11` (vistas par/impar y del secundario) nunca se ejecutó: se eligieron los negativos difíciles. Par/impar en la global no sirvió porque el tránsito ocupa 2–3 bins (`research/06`). Precisamente las binarias son el error de TESS con margen de mejora: 31 % tomadas por planeta en val y 26 % en test, frente al 9 % de Kepler.

MEDIA **B3 · Normalización por (mediana − mínimo)**

El mínimo es un solo bin: con SNR baja, la «profundidad» es sobre todo ruido. Un NO_SIGNAL normalizado queda como ruido puro de amplitud ~1 (lo que rompió el kNN). Además, toda la información de «cuánto destaca la señal sobre el ruido» se pierde en la vista. **Propuesta:** una profundidad robusta (media de los 3–5 bins centrales o un ajuste de trapecio) y un **segundo canal en unidades de ruido**: (vista − mediana)/σ fuera del tránsito. Conserva la SNR sin la profundidad absoluta, que era la variable que delataba la misión. También un canal con la dispersión o el número de puntos por bin, para que la red sepa qué bins son fiables (TESS con 5 tránsitos).

ALTA **B4 · NO_SIGNAL no se parece a una falsa alarma real**

Una estrella tranquila plegada con una efeméride prestada da una vista plana y fácil (F1 0,92–0,96). Con la efeméride de BLS, el 20–43 % pasa por planeta (`research/11` §2). Hay falsas alarmas reales y públicas que no se han usado: los TCE de los conjuntos **invertido y desordenado de Kepler DR25** (NASA Exoplanet Archive), creados para medir la fiabilidad del catálogo, y las **98 FA de TESS** en ExoFOP (87 excluidas en el dataset). Ver P7.

BAJA **B5 · Sistemas multiplanetarios y aplanado**

Cada estrella usa una efeméride. En sistemas con varias señales, los otros tránsitos no se enmascaran y ensucian la global. Además, la multiplicidad es muy informativa: los candidatos en sistemas múltiples son casi siempre planetas (Lissauer et al. 2012), y se puede medir desde la curva (P20). Comprobación barata: comparar el acierto en estrellas con `n_planets_in_system` > 1 frente a 1. Por otro lado, el aplanado Savitzky–Golay de lightkurve (y la ventana ciega de 1,5 d en BLS) puede deformar los tránsitos largos. Alternativa: el biweight de `wotan`, solo si la comprobación por duración lo justifica.

BAJA **B6 · Estrellas compartidas en el modelo final**

`final_model.py` no excluye las estrellas compartidas entre misiones (sí lo hace LOMO). Lo he comprobado: solo afecta a **1 estrella de test** (EPIC_248639411, cuyo gemelo TIC_349986198 está en train de TESS). El efecto es despreciable, pero conviene anotarlo en la model card.

4.3 Ingeniería, documentación y Notion

ALTA **C1 · La fase 6 está «Hecho» en Notion pero no en git**

`git status` muestra sin versionar `research/14`, `scripts/models/temperature.py`, `tess_multisector.py`, `scripts/data/build_tess_multisector.py`, `scripts/checks/tess_multi_compare.py`, sus CSV y dos PDF de `docs/` y `research/`. La regla del proyecto exige un artefacto verificable. Además, la temperatura (`data/models/final_temperature.json`) formará parte del modelo que se congele.

MEDIA **C2 · Documentos de contexto desactualizados**

`AGENTS.md` dice «Fase 3 preparada, sin ejecutar». `README.md` tiene el estado del 4 nov. `CONTEXTO.md` §7 lista 5 fases y §9 habla del inicio de la fase 4. La descripción de la base Fases en Notion dice «Las 5 fases del proyecto». Un agente que lea `AGENTS.md` trabajaría con información falsa.

MEDIA **C3 · Antes de congelar predicciones hace falta un «registro de modelo»**

La validación prospectiva solo vale si se puede demostrar qué modelo exacto predijo y cuándo. Hoy los pesos están en `data/` (fuera de git) y no hay hash de los pesos, de la configuración ni de las vistas en los resultados (#41 sin hacer). **Propuesta:** un manifiesto con el SHA-256 de `final_seed{0..4}.pt`, `final_temperature.json` y el CSV de predicciones, el commit y la fecha, publicado con sello de tiempo externo (un release de GitHub o un DOI de Zenodo).

BAJA **C4 · Coherencia en Notion**

La fase 9 está «En curso» sin ninguna tarea en proceso. Hay tareas P0 en stand-by (#11, reglas físicas): si están aparcadas, su prioridad debería bajar o anotarse que es la original. Sin CI, los scripts no tienen tests y los de PyTorch solo corren en WSL (#78).

5. Métodos nuevos: exploración

Cada propuesta indica la idea, por qué encaja con lo que ya se sabe del proyecto, el experimento mínimo con un criterio fijado antes y su coste. Todas respetan la regla del proyecto: el modelo solo ve la curva y sus derivadas. P13 y P18 usan otra información, pero como variante opcional o en el integrador, no en el modelo portable.

5.1 Representación y arquitectura

P1 · Transformer sobre el conjunto de tránsitos individuales — L · novedad alta

Idea. En lugar de la mediana plegada, cada tránsito es un token: una ventana local alrededor de cada época esperada (p. ej. ±3 duraciones, 64 bins), con su paridad, su sector y su calidad. Un Transformer pequeño (2–4 capas, atención con máscara para un número variable de tránsitos) los combina y los une a la rama global. Ve lo que la mediana borra: par/impar sin trucos de bins, profundidades que cambian entre tránsitos (mezclas, sistemáticos), un único tránsito anómalo que domina la vista y TTV. Además usa todos los sectores sin replegar: más sectores son simplemente más tokens.

Por qué aquí. TESS falla con ≤ 8 tránsitos (acierto de FP ~30 %). La par/impar global no aportó porque el tránsito ocupa 2–3 bins, y replegar con varios sectores no dio un resultado claro.

Experimento mínimo. Ventanas por tránsito desde los FITS en caché (sin descargas). Mismas estrellas que la CNN, 5 semillas, val. Criterio: macro-F1 de TESS mayor con un IC sin 0, o binarias → PLANET por debajo del 31 %. Después, LOMO.

Riesgo. Sobreajuste con pocos datos: modelo pequeño y, si hace falta, preentrenamiento (P9). En la búsqueda no encontré vetting con atención sobre tránsitos individuales; sí existe un Transformer sobre la curva completa de TESS (Salinas et al. 2025) y atención aditiva sobre LSTM (Hernández-Carnerero et al. 2025).

P2 · Vistas tipo ExoMiner, pero portables — M · novedad baja, valor esperado alto

Idea. Cuatro vistas nuevas: local par e impar (alrededor de cada tránsito, no en la global); local del secundario, centrada en la fase del mínimo más profundo fuera del tránsito, buscada en la global; local de alta resolución (±2 duraciones, 101–201 bins); y un canal de dispersión por bin. Cada una en su rama convolucional, como ExoMiner.

Por qué aquí. Ataca B1 y B2, es decir, las binarias de TESS. Todo se calcula desde la curva: es portable a CoRoT y a PLATO.

Experimento mínimo. Replegar desde la caché (~5 h). Medir primero cada vista con una logística barata (AUC binaria frente a FP en val) y después la CNN con ramas añadidas, con 5 semillas. Criterio: F1 de FP en TESS mayor y binarias → PLANET menor, sin empeorar Kepler.

P3 · Doble normalización: forma + unidades de ruido — S · novedad media

Dos canales por vista: la forma (dividida por una profundidad robusta) y la señal en σ de su propio ruido (B3). La red ve la forma y cuánto destaca, pero no la profundidad absoluta en ppm, que es la que depende del telescopio. Experimento: misma CNN con 2 canales, val y LOMO. Criterio: macro-F1 medio ≥ base y menos «FP débil → NO_SIGNAL».

P4 · Ablación de la rama global y modelo más pequeño — XS–S · novedad baja

La rama global tiene 5 bloques y la mayor parte de los parámetros, y la parada temprana llega en las épocas 2–30, lo que indica memorización rápida. Probar sin global, con una global de 2 bloques o con una global de 1 001 bins. Si la global no aporta, se reduce el sobreajuste y queda sitio para las vistas de P2.

5.2 Física dentro del modelo

P5 · Análisis por síntesis con un modelo físico diferenciable

L · novedad media–alta

Idea. Un codificador predice los parámetros de dos hipótesis:

- **(a) Planeta:** Rp/R★, parámetro de impacto, a/R★ y oscurecimiento del limbo cuadrático.
- **(b) Binaria:** profundidades primaria y secundaria, fase del secundario, forma V, variación elipsoidal y dilución.

Un «renderizador» diferenciable en PyTorch reconstruye las vistas con cada hipótesis. Para empezar basta un trapecio con suavizado; después, Mandel–Agol. La clase se decide con los parámetros y con el error de reconstrucción de cada hipótesis, como una razón de verosimilitud aprendida.

Por qué aquí. Da la explicabilidad que necesita el informe de la fase 8 («radio relativo ~0,1; densidad estelar implícita ρ★ desde a/R★ y P»). Una ρ★ imposible delata una gigante o una mezcla *sin catálogo* (Seager & Mallén-Ornelas 2003). Además, el EDA mostró que la regla de densidad tenía una precisión de FP de 0,94.

Experimento mínimo. Versión trapecio. Comprobar que Rp/R★ estimado correlaciona con la profundidad del catálogo (validación física) y que el macro-F1 no baja. Variante barata: ajustar U frente a V y con/sin secundario por mínimos cuadrados y usar el ΔBIC como rasgo (no es lo mismo que los z de par/impar que fallaron).

Novedad. Existen modelos de tránsito diferenciables (jaxoplanet, eclipsoid) y redes con restricciones físicas para tránsitos. No encontré un decodificador de dos hipótesis usado para el vetting.

5.3 Datos sintéticos y negativos realistas

P6 · Inyección de binarias y planetas en curvas reales («sim-to-real»)

M–L · novedad media

Idea. Ya existe el inyector de tránsitos (`research/12`). Hay que ampliarlo con un modelo analítico de binaria:

- dos eclipses con cociente de profundidades;
- forma V según el parámetro de impacto;
- variación elipsoidal y reflexión;
- **dilución** para las binarias de fondo, que bajan la profundidad hasta parecer un planeta pero conservan la forma.

También se inyectan planetas con la **distribución de periodos de TESS** (más P < 2 d), sobre curvas reales sin señal de las tres misiones.

Por qué aquí. Ataca a la vez las dos causas del fallo en TESS: las binarias que se escapan y el sesgo aprendido «periodo corto → binaria» (en Kepler y K2, el 33–59 % de los FP tienen P < 2 d). Las etiquetas son exactas e ilimitadas.

Experimento mínimo. Solo se entrena con sintéticos y **solo se evalúa en real**, porque un modelo entrenado en sintético puede parecer perfecto en sintético y fallar en real, como avisa la literatura de PHOEBE. Criterio: acierto en planetas de TESS con P < 2 d (hoy falla en 40 de 82) y binarias → PLANET menor, en LOMO TESS. Precedente: Chaushev et al. (2019) inyectaron binarias para NGTS.

P7 · Negativos realistas: falsas alarmas de verdad

M · novedad media

Idea. Los TCE del conjunto **invertido** de Kepler DR25 son detecciones de la tubería oficial sobre la curva dada la vuelta. Su efeméride está en el archivo y las estrellas son de Kepler: se puede invertir nuestra propia curva aplanada y plegarla en esa efeméride, sin descargas nuevas para las estrellas en caché. Se añaden los **desordenados** (más trabajo: reordenar por años), las FA de TESS y los picos de BLS que ya existen.

Uso doble. Como NO_SIGNAL «con estructura» al entrenar y como conjunto aparte para medir la tasa de falsas alarmas con ruido real.

Aviso. La inversión no reproduce la luz dispersa de TESS: LEO-Vetter usó solo los desordenados en TESS. Criterio: NO_SIGNAL de BLS → PLANET por debajo del 7,7 % (el modelo de negativos difíciles en Kepler) sin perder más de 0,01 con la efeméride de catálogo.

P8 · Entrenamiento robusto a errores de efeméride S–M · novedad media

Idea. Al entrenar, perturbar la época (±0,1–0,3 duraciones), el periodo (error relativo típico de un TOI propagado) y la duración (×0,7–1,4). Hay que precalcular K vistas por estrella desde la caché.

Por qué aquí. Con la efeméride de BLS, los FP con el periodo correcto bajan del 89 % al 74 % de acierto, probablemente por la duración o la época estimadas. Los TOIs que se observarán tienen efemérides con error que crece con el tiempo (#90), y un aficionado dará efemérides imperfectas.

Primero, la prueba de estrés (XS–S): replegar val con perturbaciones y medir cuánto cae el modelo actual. Si apenas cae, no hace falta entrenar con el aumento.

5.4 Pocas etiquetas y datos sin etiquetar

P9 · Preentrenamiento autosupervisado propio L–XL · novedad media–alta

Idea. Un modelo fundacional pequeño, entrenado con curvas de tránsito sin etiquetar: reconstrucción de bloques enmascarados sobre las series sin plegar (`data/sample/series`, ya construidas) o sobre las vistas, y contraste con aumentos físicos (recorte de sector, ruido, reflexión). Datos: las ~13 000 curvas en caché y, si se quiere, millones de curvas FFI sin etiquetar.

Por qué aquí. MOMENT no superó a la CNN porque es genérico (no vio curvas astronómicas). FALCO (2025) muestra que el preentrenamiento autosupervisado en Kepler funciona para variabilidad estelar. La pregunta útil es si hace que 234 etiquetas de TESS valgan más (la curva de aprendizaje de la fase 3 era casi plana).

Experimento. Sonda lineal y ajuste fino en LOMO TESS, más la curva de aprendizaje con 2 %, 10 % y 100 % de TESS.

P10 · Etiquetas débiles como etiquetas blandas S–M · novedad baja

Usar los candidatos de Kepler con `koi_score` como probabilidad objetivo y los de K2 con una etiqueta suavizada. Alternativa: aprendizaje positivo-sin-etiquetar. Los PC de TESS se quedan fuera (A5). Es la variante «fuertes + débiles» que el protocolo ya prevé. Criterio en val con etiquetas fuertes.

P11 · Aprendizaje confiado para encontrar etiquetas probablemente erróneas S · novedad media

Idea. Con predicciones fuera de pliegue sobre train, el método de «confident learning» (Northcutt et al.; unas 30 líneas de NumPy, sin dependencia nueva) marca las estrellas cuya etiqueta contradice con fuerza al modelo.

Por qué aquí. Las etiquetas de TESS son ruidosas: un tercio de los FP solo dice «TFOP FP», 58 PLANET del dataset son hoy FP o FA y ExoMiner++ reconoce el mismo problema.

Resultado científico. Una lista de disposiciones sospechosas para revisar a mano en ExoFOP. Después, reentrenar sin ellas con un criterio en val.

5.5 Generalización entre telescopios (el núcleo del proyecto)

P12 · Entrenamiento adversarial de dominio (DANN) y Group DRO M · novedad alta

Idea. Un discriminador de misión sobre la representación interna, con inversión del gradiente (Ganin et al. 2016): la red aprende rasgos útiles para la clase que no delatan el telescopio. Variante: Group DRO por misión. λ se elige en los folds internos y se evalúa en LOMO.

Por qué aquí. La misión se adivina con un AUC de 0,73–0,92 y la brecha de TESS en LOMO es −0,08. AdaBN falló porque el problema no es de escala, y DANN ataca otra cosa: lo que la red *usa*.

Riesgo real. Parte de lo que delata la misión es física de verdad (TESS tiene más planetas cortos). Forzar la invariancia puede quitar información útil, y por eso hay que medirlo. No encontré DANN aplicado a Kepler → TESS. Un trabajo de 2025 lo cita como trabajo futuro.

P13 · Centroide como modalidad opcional S–M · novedad media

Idea. Entrenar con el canal de centroide apagado al azar (p = 0,5) y una bandera de presencia. Así, un solo modelo usa el centroide donde la escala de píxel lo permite (Kepler) y funciona sin él (TESS, CoRoT, datos de tierra).

Por qué aquí. El centroide sube los FP «invisibles» de Kepler del 66 % al 80 %, que es justo el techo físico, pero empeora K2/TESS. «LOMO con centroide» quedó pendiente en `research/07`. El modelo «solo curva» sigue siendo la versión portable oficial.

P14 · TESS FFI como cuarta «misión» y prueba temporal (sustituye a CoRoT) M · novedad media

Idea. Las curvas de imágenes completas (QLP, TESS-SPOC; cadencias de 30 min, 10 min y 200 s) son otro producto de datos, con otra fotometría y otros sistemáticos. Son un cambio de dominio real y accesible. Los ~885 TOIs etiquetados fuera del dataset (unos 280 FP solo en FFI) se usan **solo para evaluar**, nunca para entrenar, así que no hay atajo de producto, que fue la razón para aparcar #94.

Experimento. El modelo final congelado, sin tocar, se evalúa en ese conjunto y se informa como «telescopio nuevo». Cuidado con el presupuesto de descargas (~23 de 50 GB usados).

5.6 Incertidumbre y decisiones

P15 · Predicción conformal por misión S · novedad media–alta

Idea. En lugar de una clase, un conjunto con cobertura garantizada (p. ej. 90 %): {PLANET}, {FP}, {PLANET, FP}. Se calibra en val con la versión Mondrian, por misión y clase. Para un telescopio nuevo, la versión ponderada por cambio de covariables o la de peor caso.

Por qué aquí. Es la forma honesta de decir «con la curva sola no se puede decidir», justo en los FP de contaminación. Es directamente útil para el informe al aficionado. EXOVEIL (2026) usa conformal dividido en detección. Se añaden curvas de riesgo frente a cobertura (clasificación selectiva) por misión.

P16 · Detector fuera de distribución sobre la representación interna S · novedad media

Distancia de Mahalanobis por clase en la penúltima capa (Lee et al. 2018), o una puntuación de energía, con el umbral fijado en val. Marca las curvas que no se parecen a nada del entrenamiento: datos de tierra de aficionados, FFI, sistemáticos raros. Es la base técnica de la monitorización de deriva (#82). Prueba: ¿marca las curvas FFI de P14 y los planetas de K2 que BLS no encuentra?

5.7 Investigación con impacto (fases 7 y 8)

P17 · Validación pseudo-prospectiva por fecha de alerta S–M · novedad alta

Idea. ExoFOP tiene la «Date TOI Alerted». Se reentrena el modelo sin los TOIs alertados después de una fecha de corte (p. ej. 2024-01-01) y se evalúa en los que, alertados después, ya tienen disposición. Da hoy una estimación de «¿habría acertado el futuro?» y mide la deriva de etiquetas: 58 PLANET del dataset son hoy FP o FA.

Por qué aquí. La validación prospectiva de verdad (#87–#92) puede tardar meses o años en acumular disposiciones nuevas. Conviene medir el ritmo: cuántos PC cambian al mes. Las dos se complementan: la pseudo-prospectiva da resultados ya y la real es la prueba definitiva.

P18 · Recomendación por tipo de incertidumbre (valor de la información) M · novedad alta

Idea. El punto ciego del modelo (FP por contaminación de una estrella vecina) es *exactamente* lo que resuelve la fotometría desde tierra del TFOP SG1: con píxeles más pequeños se ve si el eclipse está en la vecina. El integrador de la fase 8 puntuaría alto los TOIs con forma de planeta (nuestro modelo) y riesgo de contaminación (píxel de 21″ de TESS, vecinas de Gaia capaces de reproducir la profundidad), filtrados por observabilidad y detectabilidad.

Por qué es valioso. Convierte el techo físico en una propiedad de la herramienta: «aquí tu observación aporta lo que un modelo no puede». El catálogo solo se usa en el integrador, no en el modelo. El TFOP prioriza con sus propios criterios; no encontré una herramienta pública que combine esto con un clasificador.

P19 · Desacuerdos con ExoMiner++ como resultado científico S · novedad media

Amplía #102: no solo la concordancia, sino la lista de TOIs donde «solo curva» y ExoMiner++ discrepan, clasificados por motivo (contaminación, pocos tránsitos, periodo corto, señal débil). Cuantifica qué información fuera de la curva decide cada caso, y es material para una nota corta (RNAAS) junto con la validación prospectiva.

P20 · Multiplicidad medida desde la curva M · novedad media

Tras enmascarar la señal dada, buscar otras señales en la misma curva (BLS iterativo o el detector U-Net de la fase 7). Que una estrella tenga varias señales baja mucho la probabilidad de FP (el «impulso por multiplicidad»), y aquí se mediría sin catálogo. Primero, la comprobación de B5.

P21 · U-Net por punto con LOMO y PLATO simulado con PSLS L · ya prevista (#101, #103)

Sugerencias para la tarea prevista:

- entrenar con inyecciones en curvas reales de las tres misiones, reutilizando P6: planetas, binarias y binarias de fondo, como PANOPTICON;
- evaluar con LOMO;
- usar **PSLS** (`pip install psls`, curvas de luz) como dominio PLATO barato antes de PlatoSim3, que trabaja a nivel de píxel. Como referencia: PANOPTICON recupera el 90 % con un 1 % de falsas alarmas en PLATO simulado.

P22 · Asistente con LLM: que explique, no que clasifique M · tarea #83

El LLM recibe los campos calculados del informe (probabilidades calibradas, conjunto conformal, ρ★ implícita, par/impar, tipo probable de FP) y los explica en español. No debe juzgar la curva: AstroMMBench (2025) muestra que los modelos multimodales leen curvas de luz de forma inconsistente. Es una buena demostración de «IA con herramientas» para la web.

6. Hoja de ruta propuesta

Respeta tu orden de fases: la siguiente es la 7. Mi propuesta es **congelar ya la v1**, porque el reloj de la validación prospectiva empieza al congelar, y llevar las mejoras como una «v2» que se congela aparte, con su propia fecha. Así ninguna mejora retrasa la fase 7. Abrir esa línea v2 es decisión tuya.

Cuándo	Qué	Coste total
Ya (higiene)	C1 commit de la fase 6 · C2 actualizar AGENTS/README/CONTEXTO · C3 manifiesto con hashes · A6 decidir por escrito los negativos difíciles	~2 h
Fase 7, arranque	#85 datos de TOIs abiertos → #87 congelar la v1 con manifiesto y release · P17 pseudo-prospectiva · A7 probabilidad binaria calibrada para TOIs	2–3 días
Quick wins de diagnóstico (en paralelo, solo miden)	A1 multisector en inferencia · P8 prueba de estrés de la efeméride · B5 multis frente a únicas · P4 ablación de la global · A2 selección con 3 semillas	~1 día
Modelo v2 (si lo apruebas)	A4 pesos por misión → P2 vistas nuevas → P7 negativos DR25 → P6 inyección de binarias. Cada paso con su criterio fijado antes, CV sobre train + val y LOMO	1–2 semanas
Fase 7, investigación	#101 U-Net (con P6 y PSLS) · P14 FFI como cuarta misión · #102 + P19 desacuerdos con ExoMiner++ · P12 DANN	2–3 semanas
Fase 8	#96 informe + P15 conformal + P16 fuera de distribución · P5 versión trapecio para explicar · P18 integrador por valor de la información	2 semanas
Apuestas largas	P1 Transformer de tránsitos · P9 preentrenamiento autosupervisado · P5 completo	3–6 semanas

Mapa impacto frente a coste

	Coste bajo (XS–S)	Coste medio (M)	Coste alto (L–XL)
Impacto alto	A1 multisector en inferencia · A4 pesos por misión · P15 conformal · P17 pseudo-prospectiva · C1/C3	P2 vistas nuevas · P7 negativos reales · P6 binarias sintéticas · P18 integrador	P1 Transformer de tránsitos · P9 preentrenamiento
Impacto medio	P8 estrés de efeméride · P11 etiquetas sospechosas · P16 fuera de distribución · P3 doble normalización	P12 DANN · P13 centroide opcional · P14 FFI · P19 · P20 multiplicidad	P5 física diferenciable · P21 U-Net
Impacto bajo	A2, A3, A8, B6, C4 · P4 ablación	P10 etiquetas blandas · B5 aplanado	P22 asistente LLM

El impacto es una estimación cualitativa a partir de los errores medidos (sobre todo los FP de TESS y el ruido que pasa en búsqueda), no una medición.

7. Decisiones que te tocan

1. **¿Congelar ya la v1 (modelo de la fase 4 + temperaturas) o esperar a una v2?** Recomiendo congelar ya y congelar la v2 aparte.
2. **Negativos difíciles.** Modelo base para los modos con efeméride y el de negativos difíciles solo para búsqueda (recomendado), adoptarlo para todo o descartarlo.
3. **Frontera FP «no parece tránsito» frente a NO_SIGNAL.** Mantenerla como está y documentarla (recomendado para la v1), fusionar las clases en el informe o reetiquetar los nt como NO_SIGNAL en la v2.
4. **¿Abrir una línea «modelo v2»** (A4, P2, P7, P6) en paralelo a la fase 7, dentro de la fase 7 o dejarla en stand-by?
5. **Apuesta larga:** P1 (Transformer de tránsitos, mi favorita por novedad y encaje con TESS), P9 (preentrenamiento) o P5 (física diferenciable, la mejor para explicar).
6. **Etiquetas débiles de Kepler y K2** como blandas (P10), siempre sin los PC de TESS.

7. **¿Crear en Notion** tareas para las propuestas que elijas, con su fase, prioridad y esfuerzo?

---

8. Qué haría distinto un equipo real

- **Preregistro** de la validación prospectiva (OSF o Zenodo con DOI) con el manifiesto de hashes. Sin un sello de tiempo externo, «congelado» es una promesa.
- **Análisis de potencia antes de cada experimento**: con 302 estrellas de val de TESS, un efecto de +0,02 no se puede ver, y conviene saberlo antes de gastar 3 horas de GPU.
- **Registro de modelos y versionado de datos**: al menos un manifiesto con el hash de cada carpeta de vistas (`views`, `views_bls`, `views_tess_multi`) y de los pesos. DVC o MLflow, cuando el número de artefactos lo pida (#41, #81).
- **CI mínima**: tests de `src/` en cada push, con un conjunto de datos de juguete (#78), y una prueba de humo por script.
- **Model card con el techo físico** (#39, #79): el rendimiento por tipo de FP, por SNR y por número de tránsitos, y la frase «no sirve para validar planetas, sirve para priorizar».
- **Revisión externa**: enseñar la validación prospectiva y LOMO al grupo de exoplanetas e IA de la Universidad de Oviedo antes de congelar. Un astrónomo detectará rápido los casos que el modelo no puede ver.
- **Monitorización** en la API: la fracción de curvas marcadas como fuera de distribución (P16) y la distribución de probabilidades por semana (#82).

---

9. Fuentes

Proyecto: `research/01–14`, `CONTEXTO.md`, `src/exoplanet/*.py`, `results/models/*.csv`, Notion (bases Fases y Tareas, consultadas el 6 nov 2026; ninguna nota de Jairo pendiente). Las cifras de la tabla binaria de la sección 2 y la comprobación de estrellas compartidas (B6) se calcularon en esta auditoría a partir de las predicciones guardadas. Literatura (búsquedas del 6 nov 2026, no exhaustivas):

- Shallue & Vanderburg 2018, AstroNet — https://arxiv.org/abs/1712.05044
- Valizadegan et al. 2022, ExoMiner — https://arxiv.org/abs/2111.10009 · 2025, ExoMiner++ — https://arxiv.org/abs/2502.09790
- Srinivasan 2026, «Depth-Blind by Design» (NeurIPS) — https://neurips.cc/virtual/2026/164256 (solo el resumen)
- Kepler DR25, datos simulados (invertido, desordenado, inyectado) — https://exoplanetarchive.ipac.caltech.edu/docs/KeplerSimulated.html · Thompson et al. 2018 — https://arxiv.org/abs/1710.06758
- LEO-Vetter 2025 — https://arxiv.org/abs/2509.10619
- FALCO 2025, modelo fundacional de curvas de Kepler — https://arxiv.org/abs/2504.20290 · Astromer 2 — https://arxiv.org/abs/2502.02717
- EXOVEIL 2026 (conformal y descomposición de incertidumbre) — https://arxiv.org/abs/2606.02778
- PANOPTICON 2025 (U-Net, PLATO) — https://arxiv.org/abs/2409.03466 · PSLS — https://pypi.org/project/psls · PlatoSim3 — http://ivs-kuleuven.github.io/PlatoSim3/
- Salinas et al. 2025, Transformer en FFI de TESS (MNRAS)
- Thomas et al. 2025, CNN/RNN con atención en Kepler DR25 (adaptación de dominio como trabajo futuro) — https://arxiv.org/abs/2509.04793
- Chaushev et al. 2019, inyección de binarias para NGTS — https://arxiv.org/abs/1907.11109
- Inferencia basada en simulación para binarias con PHOEBE — https://arxiv.org/abs/2604.19919 · aviso sim-to-real — https://arxiv.org/abs/2604.01281
- AstroMMBench 2025 (LLM multimodales en astronomía) — https://arxiv.org/abs/2510.00063
- Northcutt et al., errores de etiqueta — https://arxiv.org/abs/2103.14749
- Encuestas de adaptación en test — https://arxiv.org/abs/2303.15361 · https://arxiv.org/abs/2411.03687
- QLP (MAST) — https://archive.stsci.edu/hlsp/qlp · Productos de TESS — https://heasarc.gsfc.nasa.gov/docs/tess/data-products.html
- Clásicos citados sin enlace: Ganin et al. 2016 (DANN), Lee et al. 2018 (Mahalanobis), Lissauer et al. 2012 (multiplicidad), Seager & Mallén-Ornelas 2003 (densidad desde el tránsito), Saerens et al. 2002 (cambio de prior).