Variables y metodología: exoplanet-transit-detection

Fuente: Hugging Face, *bingbangboom/exoplanet-transit-detection* (licencia CC-BY-4.0). 23 567 filas (train 18 853 / val 2 357 / test 2 357), formato Parquet. Misiones: Kepler, K2 y TESS.

> Cada fila es **una estrella** con su curva de luz ya preprocesada, metadatos estelares, parámetros del tránsito y una etiqueta. Las definiciones de las columnas estelares (sección 5) están completadas con el significado estándar de los catálogos de la NASA a partir del nombre; la página del dataset no las detalla.

1. Identificación y etiquetas

Variable	Tipo	Explicación
`star_id`	texto	Identificador único de la estrella con prefijo de misión: KIC_ (Kepler), TIC_ (TESS), EPIC_ (K2).
`mission`	texto	Misión de origen: `kepler`, `k2` o `tess`. Importante para evitar sesgos: cada misión tiene distinto ruido y cadencia.
`cadence`	texto	Frecuencia de muestreo: `long` (≈30 min, Kepler/K2) o `2min` (TESS).
`disposition`	texto	**Etiqueta objetivo**. `PLANET` (planeta confirmado o candidato), `FALSE_POSITIVE` (falso positivo) o `NO_SIGNAL` (estrella Kepler sin tránsito detectado). Reparto: 41,5 % / 25,2 % / 33,3 %.
`label_source`	texto	Origen de la etiqueta: `kepler_robovetter`, `tess_tfopwg`, `k2_project` o `no_signal`.
`confidence_score`	decimal 0–1	Etiqueta suave de confianza. Kepler confirmado = 1,0; Kepler Robovetter = *koi_score*; TESS candidato = 0,9; TESS ambiguo = 0,5; TESS falso positivo = 0,0; K2 confirmado = 1,0; K2 candidato = 0,7; NO_SIGNAL = 1,0.
`has_transit_params`	booleano	Verdadero si existen periodo, duración y época. Solo entonces se pueden calcular las curvas plegadas.

2. Curvas de luz (arrays float32)

Se guardan como bytes y se leen con `np.frombuffer(x, dtype=np.float32)`. El flujo está normalizado dividiendo por su mediana (el brillo normal vale ≈1,0).

Variable	Longitud	Explicación

`flux_raw`	20 000	Curva de luz completa, en orden temporal, sin plegar. Pasos: unión de trimestres/sectores (*stitch*), normalización por la mediana, eliminación de valores a más de 5σ, interpolación de NaN y remuestreo a 20 000 puntos. Es la única vista con datos reales en NO_SIGNAL.
`flux_global`	201	Curva plegada al periodo orbital, con toda la fase. Muestra la forma global: tránsito, posible eclipse secundario y variabilidad.
`flux_local`	81	Zoom alrededor del tránsito (±4 veces su duración). Muestra la forma fina del tránsito (¿en U o en V?).
`flux_odd`	201	Plegado usando solo los tránsitos impares.
`flux_even`	201	Plegado usando solo los tránsitos pares. Comparar con *flux_odd* ayuda a detectar binarias eclipsantes: si las profundidades difieren, no es un planeta.

`flux_raw_len, flux_global_len, flux_local_len, flux_folded_len`	entero	Longitud de cada array (20 000, 201, 81 y 201). Sirven de control de consistencia.

En las filas NO_SIGNAL las cuatro vistas plegadas están rellenas de ceros, porque no hay periodo con el que plegar.

3. Banderas de falso positivo (solo Kepler)

Son NaN en TESS, K2 y NO_SIGNAL. Proceden del clasificador automático Robovetter de Kepler.

Variable	Tipo	Explicación
`fp_flag_not_transit`	0/1	La señal no tiene forma de tránsito (ruido, instrumento o variabilidad estelar).
`fp_flag_stellar`	0/1	Eclipse estelar: probablemente una binaria eclipsante.
`fp_flag_centroid`	0/1	El centroide de la imagen se desplaza durante el evento, lo que indica que la señal viene de otra estrella cercana.
`fp_flag_ephemeris`	0/1	La señal comparte periodo y época con otro objeto, así que es contaminación por una señal vecina.
`disposition_disputed`	0/1	La clasificación cambió entre versiones trimestrales del catálogo Kepler; indica etiqueta menos fiable.

4. Parámetros del tránsito (NaN en NO_SIGNAL)

Variable	Unidad	Explicación
`period_days`	días	Periodo orbital: tiempo entre dos tránsitos consecutivos.
`epoch_bjd`	BJD	Instante del primer tránsito de referencia, en fecha juliana baricéntrica. Junto con el periodo permite predecir todos los tránsitos.
`duration_hrs`	horas	Duración del tránsito. Depende del periodo y del tamaño de la estrella.
`depth_ppm`	ppm	Profundidad: caída de brillo en partes por millón (10 000 ppm = 1 %). Es aproximadamente $(R_{planeta}/R_{estrella})^2$.
`planet_radius_earth`	radios terrestres	Radio estimado del planeta.
`n_planets_in_system`	entero	Número de planetas o candidatos conocidos en la misma estrella.
`kepoi_name`	texto	Nombre KOI (p. ej. K02718.01), solo para Kepler.

5. Propiedades estelares y observacionales

Variable	Unidad	Explicación
`teff`	K	Temperatura efectiva de la estrella (determina su color y tipo).
`logg`	$\log_{10}(\mathrm{cm/s^2})$	Gravedad superficial. Distingue enanas de gigantes.
`radius`	R⊙	Radio estelar en radios solares.
`mass`	M⊙	Masa estelar en masas solares.
`metallicity`	[Fe/H]	Abundancia de elementos pesados respecto al Sol.
`kepmag`	magnitud	Brillo aparente en la banda de Kepler. Menor valor significa más brillante y menos ruido.
`cdpp_3hr`	ppm	Ruido fotométrico esperado en intervalos de 3 horas. Cuanto menor, más fácil detectar tránsitos pequeños.
`ra`	grados	Ascensión recta (coordenada celeste).
`dec`	grados	Declinación (coordenada celeste).
`source_urls`	texto	URLs de MAST de los archivos originales de la curva de luz (trazabilidad).

6. Advertencias para modelar

- **Fuga de información (leakage):** *confidence_score*, *fp_flag_**, *disposition_disputed*, *label_source* y *kepoi_name* derivan de la propia etiqueta. No deben usarse como entradas del modelo.
- **Atajos:** *mission* o *has_transit_params* pueden revelar la clase (NO_SIGNAL es solo Kepler y no tiene parámetros).
- **Valores nulos:** muchas columnas son NaN según la misión o la clase; hay que tratarlo explícitamente.
- **Entradas razonables para un modelo de curvas de luz:** *flux_global*, *flux_local*, *flux_odd* y *flux_even*, y opcionalmente algunas variables estelares.

7. Fundamento físico del método de tránsito

Cuando un planeta pasa por delante de su estrella, bloquea una fracción del disco estelar y el flujo observado cae. Para una estrella de radio R_* y un planeta de radio R_p, la **profundidad** del tránsito es aproximadamente

$$\delta \approx (R_p / R_*)^2$$

Por eso la caída depende del **área** (cuadrado del radio): un Júpiter frente al Sol da ≈ 1 % (10 000 ppm), mientras que una Tierra da ≈ 0,008 % (≈ 84 ppm). El **periodo** P es el tiempo entre tránsitos consecutivos, y la **duración** es aproximadamente $T \approx (P/\pi)\cdot(R_*/a)$, donde a es el semieje mayor de la órbita. Para que se vea un tránsito, la órbita debe estar casi de canto respecto a nosotros, por lo que la mayoría de planetas existentes no se detectan por este método.

8. Planteamiento como problema de aprendizaje automático

- **Tarea:** clasificación multiclase supervisada. Dada la curva de luz de una estrella, predecir `disposition` ∈ {PLANET, FALSE_POSITIVE, NO_SIGNAL}.

- **Entrada:** series temporales de flujo (`flux_global`, `flux_local`, `flux_odd`, `flux_even`) y, opcionalmente, variables estelares (`teff`, `radius`, `cdpp_3hr`…).
- **Etiquetas:** provienen de catálogos de la NASA (Robovetter para Kepler, TFOPWG para TESS). No son verdad absoluta: son la mejor clasificación disponible, y algunas cambian con el tiempo (`disposition_disputed`). El modelo aprende a imitar ese criterio.
- **Representación (idea de «vista global» y «vista local»):** el enfoque habitual en la literatura, p. ej. Shallue & Vanderburg (2018, *Astronet*), pliega la curva al periodo orbital y la representa en dos escalas: una global que contiene toda la órbita (eclipses secundarios, variabilidad) y una local que amplía el tránsito (forma, profundidad). Este dataset sigue esa idea con resoluciones menores (201 y 81 puntos), y añade las vistas par/impar para detectar binarias eclipsantes.

Pipeline general

Paso	Qué se hace	Por qué
`1. Descarga`	Flujo PDCSAP desde MAST (Lightkurve).	PDCSAP ya corrige tendencias instrumentales comunes de la nave.
`2. Unión`	*Stitch* de trimestres/sectores/campañas.	Obtener una serie larga continua.
`3. Normalización`	Dividir por la mediana.	Hace comparables estrellas de brillo distinto; el nivel normal ≈ 1.
`4. Valores atípicos`	Eliminar puntos a > 5σ de la mediana local.	Quitar rayos cósmicos y errores sin borrar los tránsitos (que son caídas pequeñas).
`5. NaN`	Interpolación lineal.	Los modelos no admiten huecos.
`6. Remuestreo`	20 000 puntos en `flux_raw`.	Longitud fija de entrada.
`7. Plegado de fase`	Superponer todos los tránsitos usando periodo y época; agrupar en bins.	Al sumar muchos tránsitos, la señal crece frente al ruido aleatorio (≈ √N).
`8. Par/impar`	Plegar por separado tránsitos pares e impares.	Una binaria eclipsante alterna eclipses de distinta profundidad.

9. Mi preprocesado (`src/preprocess.py`)

Parto del split **test** (2 357 estrellas) para explorar. El script realiza:

1. **Decodificación:** convierte los bytes de cada columna en matrices `float32` de forma (n estrellas, longitud) y comprueba con `assert` que las longitudes son 20 000, 201, 81, 201 y 201.
2. **Limpieza:** reemplaza valores no finitos (NaN/inf) por 1,0, el nivel normal del flujo. Resultado: no hubo ninguno que reemplazar.
3. **Marcado de vistas vacías:** crea `folded_empty`, verdadero si las vistas plegadas son todo ceros. Hay 823 estrellas así: las 784 NO_SIGNAL más 39 candidatas de TESS/K2 sin periodo, duración o época. Las marco en lugar de borrarlas para no perder información.
4. **Variables derivadas simples:** `raw_std_ppm` (ruido global), `local_min_depth_ppm` (profundidad medida en la vista local) y `odd_even_diff_ppm` (diferencia entre mínimos par e impar).
5. **Guardado:** metadatos en `meta.parquet` y una matriz `.npy` por vista, para cargar rápido.

Lo que NO hago todavía (y habría que hacer al entrenar): escalar las curvas con estadísticos calculados solo con train si se decide estandarizar, tratar el desbalance de clases, y entrenar con los splits train y val originales. Los splits ya vienen estratificados por clase y misión, así que no hay que re-dividir. No existe todavía ningún modelo entrenado en el proyecto.

10. Tipos de curvas de luz

Tipo	Aspecto esperado	Vista donde se reconoce
`Planeta (PLANET)`	Caída pequeña (≈ 0,01–1 %), de fondo plano y bordes cortos (forma de U), profundidad igual en tránsitos pares e impares, sin eclipse secundario apreciable.	`flux_local`, `flux_odd` vs `flux_even`
`Binaria eclipsante (FALSE_POSITIVE)`	Caída profunda, a menudo en forma de V, con eclipse secundario y profundidades distintas par/impar.	`flux_global`, `flux_odd` vs `flux_even`
`Falso positivo por contaminación`	Parece un tránsito, pero lo causa otra estrella cercana; se delata por el desplazamiento del centroide, no por la forma. Esta información no está en las curvas, sino en `fp_flag_centroid`.	Solo metadatos
`Variabilidad / ruido (FALSE_POSITIVE)`	Caídas irregulares, no periódicas, por manchas, pulsaciones o instrumento.	`flux_raw`
`Sin señal (NO_SIGNAL)`	Solo ruido fotométrico alrededor de 1, sin caídas periódicas.	`flux_raw`

Observación sobre los datos reales (split test): la mediana de `raw_std_ppm` es ≈ 1 700 ppm en PLANET, ≈ 1 350 en FALSE_POSITIVE y ≈ 430 en NO_SIGNAL. La clase NO_SIGNAL es mucho más tranquila, pero esto **no** implica que los planetas sean «más ruidosos»: NO_SIGNAL es solo Kepler, mientras que PLANET incluye muchas estrellas de TESS, con más ruido. Es un ejemplo de sesgo por misión. Además, la diferencia par/impar mediana es mayor en PLANET (≈ 73 ppm) que en FALSE_POSITIVE (≈ 35 ppm), al contrario de lo esperado; el mínimo de una curva plegada es muy sensible al ruido, así que esta variable simple no sirve por sí sola.

11. Plan de modelado propuesto

1. **Baseline:** clasificador simple (regresión logística o Random Forest) sobre variables tabulares derivadas (profundidad, duración, `odd_even_diff_ppm`, `cdpp_3hr`…), sin columnas con fuga de información.
2. **Modelo de aprendizaje profundo:** CNN 1D con ramas separadas para global y local (y par/impar como canales), concatenadas y seguidas de capas densas con salida softmax de 3 clases. Se entrena con entropía cruzada, `model.train()`/`model.eval()` y semillas fijas.
3. **Evaluación:** métricas por clase (precisión, recall, F1) y F1 macro, más matriz de confusión. La exactitud (accuracy) global es poco informativa con clases desbalanceadas. Selección de

hiperparámetros solo con validación; test se usa una sola vez al final.
4. **Análisis de errores:** revisar por misión (Kepler / TESS / K2) para comprobar que el modelo no depende de la misión como atajo.

12. Limitaciones

- Las etiquetas son clasificaciones automáticas o de la comunidad, no verdades verificadas.
- El plegado depende de que el periodo ya haya sido detectado: este dataset no sirve para *descubrir* el periodo desde cero (para eso se usa p. ej. el algoritmo BLS).
- El remuestreo a 201 y 81 puntos pierde detalle fino, sobre todo en tránsitos cortos.
- Mezcla misiones con distinta cadencia y ruido, lo que introduce sesgos.
- Los resultados descritos en la sección 10 son de la exploración del split test y no de un modelo; no se ha entrenado ni evaluado ninguno.

13. Cómo ejecutar el proyecto

```
.venv\Scripts\python.exe src/preprocess.py
.venv\Scripts\streamlit.exe run app.py
```

La app tiene cuatro pestañas: **Resumen** (composición por clase y misión), **Explorador** (una estrella: curva completa, plegada global, local y par/impar), **Comparar clases** (mediana e intervalo intercuartílico, y galería aleatoria) y **Variables** (histogramas por clase).